Politechnika Warszawska
Wydział Matematyki i Nauk Informacyjnych

Automatyczna kategoryzacja tematyczna tekstów przy użyciu metryk w przestrzeni ciągów znaków

Natalia Potocka

Warszawa, 21.04.2014

Plan działania

- Cel pracy
- O metrykach słów kilka
- Postęp prac
- Co dalej?

Cel pracy

Celem pracy jest skategoryzowanie tekstów z polskiej Wikipedii pod względem tematu na podstawie liczności słów występujących w tekście. Można się spodziewać, że jeśli w dwóch tekstach występuje dużo podobnych do siebie słów, to pochodzą one z tej samej kategorii tematycznej.

Cel pracy

Celem pracy jest skategoryzowanie tekstów z polskiej Wikipedii pod względem tematu na podstawie liczności słów występujących w tekście. Można się spodziewać, że jeśli w dwóch tekstach występuje dużo podobnych do siebie słów, to pochodzą one z tej samej kategorii tematycznej.

A		B		C		D	
całka	10	całka	5	niewłaściwe	3	ułamek	4
pochodna	5	pochodna	15	powieść	7	mianownik	5
niewłaściwa	4	granica	7	granica	15	niewłaściwy	6

Cel pracy

Co ze słowami podobnymi?
Przykładowo słowa *niewłaściwy* i *niewłaściwa* mają ten sam temat, różnią się tylko rodzajem (męski / żeński). W tekstach mogą też występować błędy ortograficzne, błędy spowodowane brakami znaków diaktrycznych (*ą, ę, ł, ...*) itd. Takie słowa również chcielibyśmy traktować jako „podobne". W celu określenia jak bardzo dwa słowa są do siebie podobne, posłużą *metryki określone na napisach*.

Definicja

Napisem nazywamy skończone złączenie symboli (znaków) ze skończonego *alfabetu*, oznaczonego przez Σ. Produkt kartezjański rzędu q, $\Sigma \times \ldots \times \Sigma$ oznaczamy przez Σ^q, natomiast zbiór wszystkich skończonych napisów, które można utworzyć ze znaków z Σ oznaczamy przez Σ^*. *Pusty napis*, oznaczany ε, również należy do Σ^*. Napisy zwyczajowo będziemy oznaczać przez s, t oraz u, a ich *długość*, czyli liczbę znaków w napisie, przez $|s|$.

Definicja

Napisem nazywamy skończone złączenie symboli (znaków) ze skończonego *alfabetu*, oznaczonego przez Σ. Produkt kartezjański rzędu q, $\Sigma \times \ldots \times \Sigma$ oznaczamy przez Σ^q, natomiast zbiór wszystkich skończonych napisów, które można utworzyć ze znaków z Σ oznaczamy przez Σ^*. *Pusty napis*, oznaczany ε, również należy do Σ^*. Napisy zwyczajowo będziemy oznaczać przez s, t oraz u, a ich *długość*, czyli liczbę znaków w napisie, przez $|s|$.

Przykład. Niech Σ będzie alfabetem złożonym z 26 małych liter alfabetu łacińskiego oraz niech $s =' ala'$. Wówczas mamy $|s| = 3$, $s \in \Sigma^3$ oraz $s \in \Sigma$. Pojedyncze znaki oznaczamy przez indeks dolny, stąd mamy $s_1 =' a'$, $s_2 =' l'$, $s_3 =' a'$. [2]

O metrykach słów kilka

Definicja

Funkcję d nazywamy *metryką* na Σ^*, jeśli ma poniższe własności:

- $d(s,t) \geq 0$
- $d(s,t) = 0$ wtw $s = t$
- $d(s,t) = d(t,s)$
- $d(s,u) \leq d(s,t) + d(t,u)$,

gdzie s, t, u są napisami.

O metrykach słów kilka

Definicja

Funkcję d nazywamy *metryką* na Σ^*, jeśli ma poniższe własności:

- $d(s,t) \geq 0$
- $d(s,t) = 0$ wtw $s = t$
- $d(s,t) = d(t,s)$
- $d(s,u) \leq d(s,t) + d(t,u)$,

gdzie s, t, u są napisami.

Nie wszystkie metryki na napisach posiadają wszystkie z wyżej wymienionych właśności.

O metrykach słów kilka

Definicja

Funkcję d nazywamy *metryką* na Σ^*, jeśli ma poniższe własności:

- $d(s,t) \geq 0$
- $d(s,t) = 0$ wtw $s = t$
- $d(s,t) = d(t,s)$
- $d(s,u) \leq d(s,t) + d(t,u)$,

gdzie s, t, u są napisami.

Nie wszystkie metryki na napisach posiadają wszystkie z wyżej wymienionych właśności.
Metryki na napisach można podzielić na trzy grupy:

- oparte na operacjach edytowania (*edit operations*)
- oparte na q-gramach
- miary heurystyczne

O metrykach słów kilka

Definicja

Funkcję d nazywamy *metryką* na Σ^*, jeśli ma poniższe własności:

- $d(s,t) \geq 0$
- $d(s,t) = 0$ wtw $s = t$
- $d(s,t) = d(t,s)$
- $d(s,u) \leq d(s,t) + d(t,u)$,

gdzie s, t, u są napisami.

Nie wszystkie metryki na napisach posiadają wszystkie z wyżej wymienionych właśności.
Metryki na napisach można podzielić na trzy grupy:

- **oparte na operacjach edytowania** (*edit operations*)
- oparte na q-gramach
- miary heurystyczne

Operacje edytowania

Metryki oparte na operacjach edytowania zliczają liczbę opercji potrzebnych do przetworzenia jednego napisu w drugi. Najczęściej wymieniamymi operacjami są:

- zamiana znaku, np. $'ala' \rightarrow' ela'$
- usunięcie znaku, np. $'ala' \rightarrow' aa'$
- wstawienie znaku, np. $'ala' \rightarrow' alka'$
- transpozycja dwóch przylegających znaków, np. $'ala' \rightarrow' laa'$

Operacje edytowania

Metryki oparte na operacjach edytowania zliczają liczbę opercji potrzebnych do przetworzenia jednego napisu w drugi. Najczęściej wymieniamymi operacjami są:

- zamiana znaku, np. $'ala' \rightarrow' ela'$
- usunięcie znaku, np. $'ala' \rightarrow' aa'$
- wstawienie znaku, np. $'ala' \rightarrow' alka'$
- transpozycja dwóch przylegających znaków, np. $'ala' \rightarrow' laa'$

Przykładowe metryki: Hamminga, najdłuższego wspólnego podnapisu (*longest common substring*), Levenshteina, optymalnego dopasowania napisów (*optimal string alignment*), Damareu-Levenshteina.

Metryki oparte na operacjach edytowania

Metryka **najdłuższego wspólnego podnapisu**, ozn. d_{lcs}, zlicza liczbę usunięć i wstawień, potrzebnych do przetworzenia jednego napisu w drugi.
Np. $d_{lsc}('leia','leela') = 3$, bo $leela \xrightarrow{us.\ e} lela \xrightarrow{us.\ l} lea \xrightarrow{wst.\ i} leia$.

Metryki oparte na operacjach edytowania

Metryka **najdłuższego wspólnego podnapisu**, ozn. d_{lcs}, zlicza liczbę usunięć i wstawień, potrzebnych do przetworzenia jednego napisu w drugi.
Np. $d_{lsc}('leia',' leela') = 3$, bo $leela \xrightarrow{us.\ e} lela \xrightarrow{us.\ l} lea \xrightarrow{wst.\ i} leia$.
Uogólniona **odległość Levenshteina**, ozn. d_{lv} zlicza ważoną sumę usunięć, wstawień oraz zamian znaków, potrzebnych do przetworzenia jednego napisu w drugi.

Metryki oparte na operacjach edytowania

Metryka **najdłuższego wspólnego podnapisu**, ozn. d_{lcs}, zlicza liczbę usunięć i wstawień, potrzebnych do przetworzenia jednego napisu w drugi.
Np. $d_{lsc}('leia','leela') = 3$, bo $leela \xrightarrow{us.\ e} lela \xrightarrow{us.\ l} lea \xrightarrow{wst.\ i} leia$.
Uogólniona **odległość Levenshteina**, ozn. d_{lv} zlicza ważoną sumę usunięć, wstawień oraz zamian znaków, potrzebnych do przetworzenia jednego napisu w drugi.
Gdy za wagi przyjmuje się 1 mamy do czynienia ze zwykłą odległością Levenshteina, np.
$d_{lv}('leia','leela') = 2$, bo $leela \xrightarrow{us.\ e} lela \xrightarrow{zm.\ l\ na\ i} leia$.

Metryki oparte na operacjach edytowania

Metryka **najdłuższego wspólnego podnapisu**, ozn. d_{lcs}, zlicza liczbę usunięć i wstawień, potrzebnych do przetworzenia jednego napisu w drugi.
Np. $d_{lsc}('leia',' leela') = 3$, bo $leela \xrightarrow{us.\ e} lela \xrightarrow{us.\ l} lea \xrightarrow{wst.\ i} leia$.
Uogólniona **odległość Levenshteina**, ozn. d_{lv} zlicza ważoną sumę usunięć, wstawień oraz zamian znaków, potrzebnych do przetworzenia jednego napisu w drugi.
Gdy za wagi przyjmuje się 1 mamy do czynienia ze zwykłą odległością Levenshteina, np.
$d_{lv}('leia',' leela') = 2$, bo $leela \xrightarrow{us.\ e} lela \xrightarrow{zm.\ l\ na\ i} leia$.
Gdy za wagi przyjmiemy np. $(0.1, 1, 1)$,
$d_{lv}('leia',' leela') = 1.1$, bo $leela \xrightarrow[0.1]{us.\ e} lela \xrightarrow[1]{zm.\ l\ na\ i} leia$

Metryki oparte na operacjach edytowania

Metryka **optymalnego dopasowania napisów**, ozn. d_{osa}, zlicza liczbę usunięć, wstawień, zamian oraz transpozycji przylegających znaków, potrzebnych do przetworzenia jednego napisu w drugi. Np. $d_{osa}('leia','leela') = 2$, bo $leela \xrightarrow{us.\ e} lela \xrightarrow{zm.\ l\ na\ i} leia$.

Metryki oparte na operacjach edytowania

Metryka **optymalnego dopasowania napisów**, ozn. d_{osa}, zlicza liczbę usunięć, wstawień, zamian oraz transpozycji przylegających znaków, potrzebnych do przetworzenia jednego napisu w drugi. Np.
$d_{osa}('leia',' leela') = 2$, bo $leela \xrightarrow{us.\ e} lela \xrightarrow{zm.\ l\ na\ i} leia$.
Metryka ta nie spełnia nierówności trójkąta:
$2 = d_{osa}('ba',' ab') + d_{osa}('ab',' acb') \leq d_{osa}('ba',' acb') = 3$

Postępy prac

Co zostało zrobione?

- wczytano $1\ 075\ 568$ artykułów z polskiej Wikipedii

Postępy prac

Co zostało zrobione?

- wczytano $1\ 075\ 568$ artykułów z polskiej Wikipedii
- razem to $2\ 806\ 765$ różnych słów...

Postępy prac

Co zostało zrobione?

- wczytano $1\ 075\ 568$ artykułów z polskiej Wikipedii
- razem to $2\ 806\ 765$ różnych słów...
- ... z czego 49% wystąpiło tylko w **jednym** tekście
- ... a 44% wystąpiło tylko **jeden raz** we wszystkich tekstach

Postępy prac

Co zostało zrobione?

- wczytano $1\ 075\ 568$ artykułów z polskiej Wikipedii
- razem to $2\ 806\ 765$ różnych słów...
- ... z czego 49% wystąpiło tylko w **jednym** tekście
- ... a 44% wystąpiło tylko **jeden raz** we wszystkich tekstach

Po usunięciu tzw. *stopwords*, czyli słów nieistotnych w kontekście analizy, jak np. *a, bo, co, jak, to, w, z, że*, słów jednoliterowych oraz słów w językach obcych z niełacińskiego alfabetu, pozostało $2\ 805\ 858$ słów do analizy.

Postępy prac

Co zostało zrobione?

- wczytano $1\ 075\ 568$ artykułów z polskiej Wikipedii
- razem to $2\ 806\ 765$ różnych słów...
- ... z czego 49% wystąpiło tylko w **jednym** tekście
- ... a 44% wystąpiło tylko **jeden raz** we wszystkich tekstach

Po usunięciu tzw. *stopwords*, czyli słów nieistotnych w kontekście analizy, jak np. *a, bo, co, jak, to, w, z, że*, słów jednoliterowych oraz słów w językach obcych z niełacińskiego alfabetu, pozostało $2\ 805\ 858$ słów do analizy.
Początkowy pomysł polegał na wykorzystaniu wcześniej wspomnianych metryk do klastrowania słów metodą k-medoidów, przy czym maksymalna odległość w klastrze miała nie przekraczać zadanej liczby.

Postępy prac

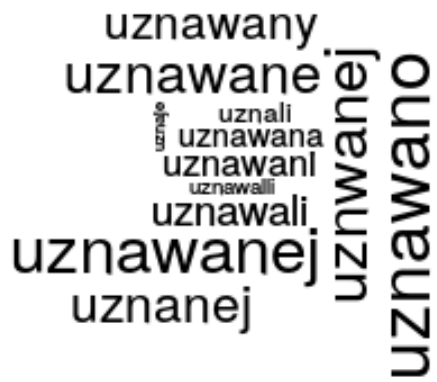

Rysunek : Przykładowe klastry utworzone przy pomocy metryki Levenshteina. Maksymalna odległość w klastrze to 7.

Rysunek : Przykładowe klastry utworzone przy pomocy metryki lcs. Maksymalna odległość w klastrze to 7.

Postępy prac

Rysunek : Przykładowe klastry utworzone przy pomocy metryki osa. Maksymalna odległość w klastrze to 7.

Postępy prac

Z powodu słabej jakości klastrowania oraz braku możliwości obliczeniowych dokonano klastrowania przy pomocy tzw. *stemmingu*. Polega on na przyporządkowaniu do słowa jego rdzenia, a więc takiej jego części, która jest odporna na odmiany przez rodzaje, przyimki, przypadki itd. Przykładowo dla słowa *używająca* rdzeniem jest *żyw*.

Postępy prac

Z powodu słabej jakości klastrowania oraz braku możliwości obliczeniowych dokonano klastrowania przy pomocy tzw. *stemmingu*. Polega on na przyporządkowaniu do słowa jego rdzenia, a więc takiej jego części, która jest odporna na odmiany przez rodzaje, przyimki, przypadki itd. Przykładowo dla słowa *używająca* rdzeniem jest *żyw*.
Do stemmingu użyto narzędzia Hunspell, które sprawdza pisownię dla wielu programów, takich jak: OpenOffice, Mozilla Firefox, Thunderbird czy Google Chrome.
Dzięki niemu udało się poklastrować $733\ 828$ słów ($\approx 26\%$ wszystkich) z czego 89% stanowiły polskie słowa $5,5\%$ - słowa angielskie, a po ponad 2% - słowa francuskie i niemieckie. Innych języków nie sprawdzano. Liczba uzyskanów klastrów to $186\ 942$.

Postępy prac

Z powodu słabej jakości klastrowania oraz braku możliwości obliczeniowych dokonano klastrowania przy pomocy tzw. *stemmingu*. Polega on na przyporządkowaniu do słowa jego rdzenia, a więc takiej jego części, która jest odporna na odmiany przez rodzaje, przyimki, przypadki itd. Przykładowo dla słowa *używająca* rdzeniem jest *żyw*.
Do stemmingu użyto narzędzia Hunspell, które sprawdza pisownię dla wielu programów, takich jak: OpenOffice, Mozilla Firefox, Thunderbird czy Google Chrome.
Dzięki niemu udało się poklastrować $733\ 828$ słów ($\approx 26\%$ wszystkich) z czego 89% stanowiły polskie słowa $5,5\%$ - słowa angielskie, a po ponad 2% - słowa francuskie i niemieckie. Innych języków nie sprawdzano. Liczba uzyskanów klastrów to $186\ 942$.
Co z pozostałymi słowami?
Słowa, które wystąpiły więcej niż raz we wszystkich tekstach, dołączono do już istniejących klastrów przy pomocy metryk. Takich słów było $973\ 855$, co dało łącznie poklastrowanych słów w liczbie $1\ 707\ 683$.

Postępy prac

Rysunek : Przykładowe klastry utworzone przy pomocy Hunspella oraz metryki lcs.

Postępy prac

Następnie dla próbki tekstów z trzech kategorii: matematyka, historia sztuki oraz wojny, dokonano klasteryzacji artykułów. Kryterium była liczność **grup słów** występujących w danym tekście. Do klastrowania użyto metody *sferycznych* k*-średnich*.

Postępy prac

Następnie dla próbki tekstów z trzech kategorii: matematyka, historia sztuki oraz wojny, dokonano klasteryzacji artykułów. Kryterium była liczność **grup słów** występujących w danym tekście. Do klastrowania użyto metody *sferycznych k-średnich*.

Przypomnienie

W metodzie k-średnich minimalizujemy

$$\sum_i d(x_i, p_{c(i)}),$$

gdzie x_i to zbiór wektorów cech, $c(i) \in \{1, \ldots, k\}$ to indentyfikator klastra, $p_1, \ldots, p_k$ to środek klastra, a d to odległość euklidesowa.

W metodzie k-średnich minimalizujemy

$$\sum_i d(x_i, p_{c(i)}),$$

gdzie x_i to zbiór wektorów cech, $c(i) \in \{1, \ldots, k\}$ to indentyfikator klastra, $p_1, \ldots, p_k$ to środek klastra, a d to odległość euklidesowa.

Metoda sferyczna

W metodzie sferycznych k-średnich minimalizujemy [1, 3]

$$\sum_i d(x_i, p_{c(i)}) = \sum_i 1 - \cos(x_i, p_{c(i)}) = \sum_i 1 - \frac{< x_i, p_{c(i)} >}{||x_i|| \cdot ||p_{c(i)}||},$$

Postępy prac

Opierając się na kategoriach z Wikipedii, poprawnie sklasyfikowanych zostało 61% z $59\ 403$ artykułów.

tytuł	kat	id_kat	kl
kościół św. rocha w poznaniu	szt	1	1
portret	szt	1	2
quantum of solace (gra komputerowa)	szt	1	2
kurka wodna (seria gier)	szt	1	2
technika macierzy rzadkich	mat	2	2
kryterium walda	mat	2	2
generalized markup language	mat	2	2
czesław falkiewicz	woj	3	3
william goodenough	woj	3	3
kazimierz gallas	woj	3	3
wacław krzywiec	woj	3	3
fabian aleksandrowicz	woj	3	3

Co dalej?

- znaleźć metodę odpowiednią do poklastrowania wszystkich artykułów (SGD?), której jakość byłaby zadowalająca
- napisać pracę :)

Bibliografia

[1] Martin Kober Christian Buchta Kurt Hornik, Ingo Feinerer. Spherical k-means clustering. *Journal of Statistical Software*, 50:1–22, 2012. http://bach-s49.wu-wien.ac.at/4000/1/paper.pdf.

[2] Mark P. J. van der Loo. The stringdist package for approximate string matching. *The R Journal*, 6:111–122, 2014. http://journal.r-project.org/archive/2014-1/loo.pdf.

[3] Stefan Wild. *Seeding Non-Negative Matrix Factorizations with the Spherical K-Means Clustering*. University of Colorado, Colorado, 2002. http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.88.1623&rep=

Dziękuję za uwagę.